

IBV
100

escuela
británica de
artes creativas
y tecnología

Buenas prácticas



Clase 01

Buenas prácticas

A continuación te compartimos algunas buenas prácticas sobre modelos de regresión lineal y series de tiempo, específicamente en el uso de modelos MA, ARMA y ARIMA, incluyen:

1. Entender la estacionariedad: Es crucial comprender y verificar la estacionariedad de las series temporales antes de aplicar modelos como ARMA o ARIMA. La prueba de Dickey-Fuller es una herramienta común para esta verificación.
2. Conocer la teoría detrás de los modelos: Antes de aplicar modelos MA, ARMA o ARIMA, es importante entender cómo funcionan y cómo los parámetros P, D y Q afectan el modelo. Esto incluye comprender la autocorrelación y la función de autocorrelación parcial.
3. Uso de simulaciones: Realizar simulaciones con datos generados puede ayudar a entender mejor el comportamiento de los modelos y cómo los parámetros afectan las predicciones.

Clase 01

Buenas prácticas

4. Interpretación de resultados: Aprender a interpretar correctamente los resultados de los modelos, incluyendo los valores de los parámetros y los indicadores de ajuste como el criterio de información de Akaike (AIC) y el criterio de información Bayesiano (BIC).

5. División de datos en conjuntos de entrenamiento y prueba: Al trabajar con datos reales, es una buena práctica dividir el conjunto de datos en grupos de entrenamiento y prueba para evaluar la capacidad predictiva del modelo.

6. Evaluación de la bondad de ajuste: Utilizar métricas como el error cuadrático medio (RMSE) y el error absoluto promedio porcentual (MAPE) para evaluar la precisión de las predicciones del modelo.

7. Aplicación en el mercado laboral: Los modelos de series de tiempo como ARIMA son ampliamente utilizados en el mercado financiero para predecir precios de acciones, en meteorología para pronosticar el clima, en economía para estimar indicadores económicos, entre otros.

Clase 01

Buenas prácticas

Ejemplo de código en Python para simular un proceso MA(1):

```
```python
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA

Simulación de un proceso MA(1)
np.random.seed(42)
n = 100
theta = 0.9
errors = np.random.normal(0, 1, n)
time_series = [errors[i] + theta * errors[i-1] for i in range(1, n)]

Graficar la serie temporal
plt.plot(time_series)
plt.title('Simulación de un proceso MA(1)')
plt.show()

Ajustar un modelo ARIMA a la serie simulada
model = ARIMA(time_series, order=(0, 0, 1))
results = model.fit()
```

# Clase 01

Buenas prácticas

```
Imprimir los resultados del ajuste
print(results.summary())
```

```
Los resultados incluyen el valor estimado del parámetro
MA(1) y los indicadores AIC y BIC
...
```

Explicación del código:

- Se importan las librerías necesarias: NumPy para la generación de errores aleatorios, Matplotlib para la visualización y Statsmodels para el modelado de series de tiempo.
- Se simula un proceso MA(1) generando errores aleatorios y aplicando la definición de un proceso MA(1).
- Se grafica la serie temporal simulada.
- Se ajusta un modelo ARIMA a la serie temporal con el orden (0, 0, 1), indicando que es un modelo MA(1).
- Se imprimen los resultados del ajuste, incluyendo el valor estimado del parámetro MA(1) y los indicadores de ajuste AIC y BIC.

# Clase 02

## Buenas prácticas

A continuación te compartimos algunas buenas prácticas sobre los modelos  $MA(q)$ ,  $ARMA(p,q)$  y  $ARIMA(p,d,q)$ :

1. Importación y limpieza de datos: Es esencial comenzar cualquier análisis de datos con la importación y limpieza adecuadas. Esto incluye eliminar columnas innecesarias y asegurarse de que el índice del DataFrame sea relevante para el análisis.

Ejemplo en el mercado laboral: En el sector financiero, los analistas de datos a menudo importan grandes conjuntos de datos de transacciones y deben limpiarlos para eliminar información irrelevante antes de realizar análisis de fraude o de riesgo crediticio.

2. Análisis de series temporales: El análisis de series temporales es una herramienta poderosa para identificar tendencias y patrones a lo largo del tiempo. Es importante comprender y aplicar pruebas de estacionalidad, como la prueba de Dickey-Fuller, para determinar si una serie es estacionaria.

# Clase 02

Buenas prácticas

Ejemplo en el mercado laboral: Las empresas de comercio electrónico utilizan el análisis de series temporales para prever las ventas futuras y ajustar sus inventarios y estrategias de marketing en consecuencia.

3. Transformación de series no estacionarias: Si una serie temporal no es estacionaria, se deben aplicar transformaciones, como la diferenciación, para estabilizar la media y la varianza.

Ejemplo en el mercado laboral: Los meteorólogos aplican transformaciones a series temporales de datos climáticos para mejorar la precisión de sus modelos predictivos.

4. Identificación de modelos ARIMA óptimos: La selección de modelos ARIMA adecuados es crucial para realizar pronósticos precisos. Utilizar criterios como el AIC ayuda a comparar y elegir el mejor modelo.

Ejemplo en el mercado laboral: Los analistas de mercado de valores pueden usar modelos ARIMA para predecir el comportamiento futuro de los precios de las acciones y asesorar a los inversores.

# Clase 02

Buenas prácticas

5. Realización de pronósticos y cálculo de intervalos de confianza: Al hacer pronósticos, es importante no solo proporcionar una estimación puntual sino también calcular intervalos de confianza para dar una idea de la incertidumbre asociada con las predicciones.

Ejemplo en el mercado laboral: Las empresas de energía pronostican la demanda futura de electricidad y calculan intervalos de confianza para asegurarse de que tienen suficiente capacidad para satisfacer la demanda.

Código ejecutable de ejemplo basado en la clase:

```
```python
import pandas as pd
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.arima_model import ARIMA

# Importar datos en un DataFrame de Pandas
df = pd.read_csv('temperaturas_ny.csv')
```


Clase 02

Buenas prácticas

```
# Limpiar datos eliminando una columna innecesaria  
df.drop('columna_innecesaria', axis=1, inplace=True)
```

```
# Cambiar el índice del DataFrame al año  
df.set_index('Year', inplace=True)
```

```
# Realizar la prueba de Dickey-Fuller para probar la  
estacionalidad  
result = adfuller(df['Temperature'])  
print('p-value:', result[1])
```

```
# Si la serie no es estacionaria, diferenciar la serie  
df['Temperature_diff'] = df['Temperature'].diff().dropna()
```

```
# Realizar la prueba de Dickey-Fuller en la serie diferenciada  
result_diff = adfuller(df['Temperature_diff'])  
print('p-value after differencing:', result_diff[1])
```

```
# Identificar los componentes óptimos de un modelo ARIMA  
plot_acf(df['Temperature_diff'])  
plot_pacf(df['Temperature_diff'])
```

Clase 02

Buenas prácticas

```
# Ajustar un modelo ARIMA (1,1,1)
model = ARIMA(df['Temperature'], order=(1,1,1))
model_fit = model.fit(dispatch=0)
```

```
# Realizar pronósticos
forecast, stderr, conf_int = model_fit.forecast(steps=5)
print('Forecast:', forecast)
'''
```

Explicación del código:

- Se importan las bibliotecas necesarias para el manejo de datos y análisis de series temporales.
- Se carga un conjunto de datos de temperatura en un DataFrame y se elimina una columna que no se necesita.
- Se establece el año como índice para facilitar el análisis.
- Se realiza la prueba de Dickey-Fuller para determinar si la serie es estacionaria.
- Si la serie no es estacionaria, se calculan las primeras diferencias y se elimina el primer valor NA.
- Se realiza nuevamente la prueba de Dickey-Fuller en la serie diferenciada.

Clase 02

Buenas prácticas

- Se generan gráficas de autocorrelación y autocorrelación parcial para identificar los parámetros del modelo ARIMA.
- Se ajusta un modelo ARIMA a la serie y se realizan pronósticos futuros.
- Se imprime el pronóstico y los intervalos de confianza asociados.

¡Mucho éxito en tus estudios!