Semana 23 | Algoritmo KNN

Presenta Juliho David Castillo Colmenares

 Considere la base de datos "recursos_humanos.csv" sobre empleados que abandonan una empresa.

	satisfaction_level	last_evaluation	number_project	average_montly_hours	time_spend_company	Work_accident	left	promotion_last_5years	sales	salary
0	0.38	0.53	2	157	3	0	1	0	sales	low
1	0.80	0.86	5	262	6	0	1	0	sales	medium
2	0.11	0.88	7	272	4	0	1	0	sales	medium
3	0.72	0.87	5	223	5	0	1	0	sales	low
4	0.37	0.52	2	159	3	0	1	0	sales	low

El objetivo es analizar porqué los empleados deciden irse con la competencia y éste podría ser un desafío serio para un departamento de recursos humanos, el cual se podría abordar mediante modelos predictivos de Machine Learning. Las variables manejadas son:

- satisfaction_level: Nivel de satisfacción.
- last_evaluation: Puntaje obtenido en la ultima evaluación.
- average_montly_hours: Promedio de horas trabajadas al mes.
- time_spend_company: Tiempo del usuario en la compañía.
- work_accident: Si el empleado ha tenido algún accidente laboral (1 = Sí, 0 = No).
- promotion_last_5years: Si el empleado ha sido promovido en los últimos 5 años.
- sales: Departamento donde trabaja.
- salary: Categoría del salario.
- left: Variable a predecir y si el empleado dejó o no la empresa (1 = Sí, 0 = No).
- Cargue la base de datos en Python y asegúrese de re-codificar las variables categóricas de manera pertinente antes de iniciar su análisis (Sugerencia: Use pd.get_dummies)

```
<class 'pandas.core.frame.DataFrame'>
        RangeIndex: 14999 entries, 0 to 14998
        Data columns (total 10 columns):
         #
             Column
                                     Non-Null Count Dtype
         ---
                                      -----
         0
             satisfaction level
                                     14999 non-null float64
         1
                                     14999 non-null float64
              last evaluation
         2
              number_project
                                     14999 non-null
                                                      int64
         3
              average_montly_hours
                                     14999 non-null
                                                      int64
         4
             time_spend_company
                                     14999 non-null int64
         5
             Work accident
                                     14999 non-null int64
         6
              left
                                     14999 non-null int64
         7
              promotion_last_5years 14999 non-null int64
         8
              sales
                                     14999 non-null
                                                      object
         9
              salary
                                     14999 non-null object
        dtypes: float64(2), int64(6), object(2)
        memory usage: 1.1+ MB
        data.head()
In [ ]:
Out[]:
           satisfaction_level last_evaluation number_project average_montly_hours time_spend_company
        0
                                    0.53
                                                     2
                                                                                            3
                      0.38
                                                                       157
        1
                      0.80
                                    0.86
                                                     5
                                                                       262
                                                     7
        2
                                    0.88
                                                                       272
                      0.11
                                                                                            4
        3
                      0.72
                                    0.87
                                                     5
                                                                       223
                                    0.52
                                                     2
                                                                       159
                                                                                            3
        4
                      0.37
In [ ]:
        data.isna().sum()
        satisfaction_level
                                  0
Out[]:
                                  0
        last evaluation
        number_project
                                  0
        average_montly_hours
                                  0
        time_spend_company
                                  0
        Work_accident
                                  0
        left
                                  0
        promotion_last_5years
                                  0
        sales
                                  0
        salary
                                  0
        dtype: int64
In [ ]: X = data.drop('left', axis=1)
        X.head()
```

```
Out[ ]:
           satisfaction_level last_evaluation number_project average_montly_hours time_spend_company Wo
                                                      2
                                                                                              3
         0
                      0.38
                                    0.53
                                                                        157
         1
                      0.80
                                    0.86
                                                      5
                                                                        262
                                    0.88
                                                      7
         2
                      0.11
                                                                        272
                                                                                              4
                                     0.87
                                                                        223
         3
                      0.72
                                                      5
                                                      2
                                                                                              3
         4
                                    0.52
                                                                        159
                      0.37
In [ ]: y = data['left']
         y.head()
              1
Out[]:
              1
         2
              1
         3
              1
         4
              1
         Name: left, dtype: int64
In [ ]: from sklearn.model_selection import train_test_split
         X train, X test, y train, y test = train test split(X, y, test size=0.3, random state=
In [ ]: X_train.info()
         <class 'pandas.core.frame.DataFrame'>
         Index: 10499 entries, 10438 to 2732
         Data columns (total 9 columns):
          #
             Column
                                      Non-Null Count Dtype
         ---
          0
              satisfaction level
                                      10499 non-null float64
          1
              last_evaluation
                                      10499 non-null float64
          2
              number_project
                                      10499 non-null int64
                                      10499 non-null int64
          3
              average montly hours
          4
              time spend company
                                      10499 non-null int64
          5
              Work accident
                                      10499 non-null int64
          6
              promotion_last_5years 10499 non-null int64
          7
              sales
                                      10499 non-null
                                                       object
                                      10499 non-null
              salary
                                                       object
         dtypes: float64(2), int64(5), object(2)
         memory usage: 820.2+ KB
In [ ]: X_train.head()
Out[]:
                satisfaction_level last_evaluation number_project average_montly_hours time_spend_company
         10438
                          0.53
                                         0.52
                                                          2
                                                                            135
                                                                                                  4
          9236
                          0.77
                                         0.53
                                                          5
                                                                            256
                                                                                                  3
           818
                          0.89
                                         0.79
                                                          3
                                                                            149
                                                                                                  2
         11503
                           0.64
                                         0.63
                                                          3
                                                                            156
                                                                                                  6
         11721
                          0.98
                                         0.74
                                                          4
                                                                            151
                                                                                                  3
```

```
In [ ]: | int_to_cat_vars = ['number_project', 'time_spend_company', 'Work_accident', 'promotion')
        X_train[int_to_cat_vars] = X_train[int_to_cat_vars].astype('object')
        X train.info()
        <class 'pandas.core.frame.DataFrame'>
        Index: 10499 entries, 10438 to 2732
        Data columns (total 9 columns):
         # Column
                                    Non-Null Count Dtype
        --- -----
                                    _____
         0
            satisfaction_level
                                    10499 non-null float64
             last evaluation
                                   10499 non-null float64
             number_project 10499 non-null object
         2
             average_montly_hours 10499 non-null int64
         3
         4
             time_spend_company 10499 non-null object
         5
             Work_accident
                                   10499 non-null object
             promotion_last_5years 10499 non-null object
         6
         7
             sales
                                    10499 non-null object
             salary
                                    10499 non-null object
        dtypes: float64(2), int64(1), object(6)
        memory usage: 820.2+ KB
        # Select numerical variables
In [ ]:
        num_vars = X_train.select_dtypes(include=['int64', 'float64']).columns.to_list()
        num_vars
        ['satisfaction_level', 'last_evaluation', 'average_montly_hours']
Out[ ]:
In [ ]: from feature_engine.discretisation import DecisionTreeDiscretiser
        discretiser = DecisionTreeDiscretiser(
            cv=3, scoring='accuracy', variables=num_vars, regression=False
        discretiser.fit(X train, y train)
        X train = discretiser.transform(X train)
        X_train[num_vars].head()
Out[]:
               satisfaction_level last_evaluation average_montly_hours
        10438
                     0.020189
                                   0.380994
                                                      0.379339
         9236
                     0.200120
                                   0.380994
                                                      0.294783
          818
                     0.200120
                                   0.277292
                                                      0.379339
        11503
                     0.020189
                                   0.024523
                                                      0.379339
        11721
                     0.000000
                                   0.024523
                                                      0.379339
In [ ]: X test = discretiser.transform(X test)
```

X_test[num_vars].head()

```
Out[ ]:
                satisfaction_level last_evaluation average_montly_hours
          1670
                       0.772984
                                      0.380994
                                                          0.379339
         13378
                       0.020189
                                      0.277292
                                                          0.020246
                       0.200120
         10233
                                      0.024523
                                                          0.020246
          4719
                       0.000000
                                      0.024523
                                                          0.020246
          7003
                       0.000000
                                      0.380994
                                                          0.020246
         from feature_engine.encoding import OneHotEncoder
In [ ]:
         ohe_enc = OneHotEncoder(drop_last=True)
         ohe_enc.fit(X_train)
         ohe_enc.variables_
         ['number_project',
Out[]:
          'time_spend_company',
          'Work_accident',
          'promotion_last_5years',
          'sales',
          'salary']
         ohe_enc.encoder_dict_
In [ ]:
         {'number_project': [2, 5, 3, 4, 6],
Out[ ]:
          'time_spend_company': [4, 3, 2, 6, 8, 10, 5],
          'Work_accident': [0],
          'promotion last 5years': [0],
          'sales': ['technical',
           'accounting',
           'support',
           'sales',
           'IT',
           'product_mng',
           'management',
           'marketing',
           'hr'],
          'salary': ['medium', 'low']}
         X_train = ohe_enc.transform(X_train)
In [ ]:
         X train.info()
```

```
<class 'pandas.core.frame.DataFrame'>
        Index: 10499 entries, 10438 to 2732
        Data columns (total 28 columns):
         #
             Column
                                     Non-Null Count Dtype
        ---
             ____
                                     -----
         0
             satisfaction level
                                     10499 non-null float64
         1
             last evaluation
                                     10499 non-null float64
         2
             average_montly_hours
                                     10499 non-null float64
         3
                                     10499 non-null int32
             number_project_2
         4
             number_project_5
                                     10499 non-null int32
         5
             number project 3
                                     10499 non-null int32
         6
                                     10499 non-null int32
             number project 4
         7
             number_project_6
                                     10499 non-null int32
         8
             time_spend_company_4
                                     10499 non-null int32
         9
                                     10499 non-null int32
             time spend company 3
         10
            time_spend_company_2
                                     10499 non-null int32
         11 time spend company 6
                                     10499 non-null int32
                                     10499 non-null int32
         12 time_spend_company_8
                                     10499 non-null int32
         13 time spend company 10
            time spend company 5
                                     10499 non-null int32
         15
            Work_accident_0
                                     10499 non-null int32
            promotion_last_5years_0 10499 non-null int32
         17
                                     10499 non-null int32
            sales technical
         18 sales accounting
                                     10499 non-null int32
                                     10499 non-null int32
         19 sales support
         20 sales_sales
                                     10499 non-null int32
                                     10499 non-null int32
         21
            sales IT
                                     10499 non-null int32
         22
            sales_product_mng
         23
            sales management
                                     10499 non-null int32
         24
            sales marketing
                                     10499 non-null int32
                                     10499 non-null int32
         25 sales hr
         26 salary_medium
                                     10499 non-null int32
             salary_low
                                     10499 non-null int32
        dtypes: float64(3), int32(25)
        memory usage: 1.3 MB
In [ ]: X_test[int_to_cat_vars] = X_test[int_to_cat_vars].astype('object')
        X test.info()
        <class 'pandas.core.frame.DataFrame'>
        Index: 4500 entries, 1670 to 2506
        Data columns (total 9 columns):
         #
            Column
                                   Non-Null Count Dtype
             ____
                                    -----
         0
             satisfaction level
                                   4500 non-null
                                                   float64
         1
             last evaluation
                                   4500 non-null
                                                   float64
         2
             number project
                                   4500 non-null
                                                   object
         3
             average montly hours
                                   4500 non-null
                                                   float64
         4
             time_spend_company
                                   4500 non-null
                                                   object
         5
             Work_accident
                                   4500 non-null
                                                   object
         6
             promotion_last_5years 4500 non-null
                                                   object
         7
             sales
                                   4500 non-null
                                                   object
         8
             salary
                                   4500 non-null
                                                   object
        dtypes: float64(3), object(6)
        memory usage: 351.6+ KB
In [ ]: X_test = ohe_enc.transform(X_test)
        X_test.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 4500 entries, 1670 to 2506
Data columns (total 28 columns):
#
    Column
                            Non-Null Count Dtype
_ _ _
                            -----
                                           ____
0
    satisfaction level
                            4500 non-null
                                           float64
1
    last evaluation
                            4500 non-null
                                           float64
2
    average_montly_hours
                            4500 non-null
                                           float64
3
    number_project_2
                            4500 non-null
                                           int32
4
    number_project_5
                            4500 non-null
                                           int32
5
    number project 3
                            4500 non-null
                                           int32
    number project 4
6
                            4500 non-null
                                           int32
7
    number_project_6
                            4500 non-null
                                           int32
8
    time_spend_company_4
                            4500 non-null
                                           int32
    time_spend_company_3
9
                            4500 non-null
                                           int32
10 time_spend_company_2
                            4500 non-null
                                           int32
11 time spend company 6
                            4500 non-null
                                           int32
12 time_spend_company_8
                            4500 non-null
                                           int32
13 time spend company 10
                            4500 non-null
                                           int32
14 time spend company 5
                            4500 non-null
                                           int32
15 Work_accident_0
                            4500 non-null
                                           int32
    promotion last 5years 0 4500 non-null
                                           int32
17
    sales_technical
                            4500 non-null
                                           int32
18 sales accounting
                            4500 non-null
                                           int32
    sales support
19
                            4500 non-null
                                           int32
20 sales_sales
                            4500 non-null
                                           int32
                            4500 non-null
21 sales IT
                                           int32
22 sales_product_mng
                            4500 non-null
                                           int32
23 sales management
                            4500 non-null
                                           int32
24 sales marketing
                            4500 non-null
                                           int32
25 sales hr
                            4500 non-null
                                           int32
26 salary_medium
                            4500 non-null
                                           int32
27 salary_low
                            4500 non-null
                                           int32
dtypes: float64(3), int32(25)
memory usage: 580.1 KB
```

• Mediante un análisis exploratorio de datos determine si esta base de datos está equilibrada o no (de acuerdo a las categorías existentes).

Analizaremos las variables categoricas para detectar aquellas que, una vez codificadas, están fuertemente dominadas por un valor.

```
In [ ]: y_train.mean()
```

 Use el método de K Vecinos más cercanos para generar un modelo predictivo. Para dicho fin, determine el valor óptimo de K evaluando distintas alternativas: k = 1, 2,, 20
 Asegúrese de respaldar su recomendación de la k óptima en base a una tabla que compare en cada caso las diversas precisiones comentadas en esta lección.

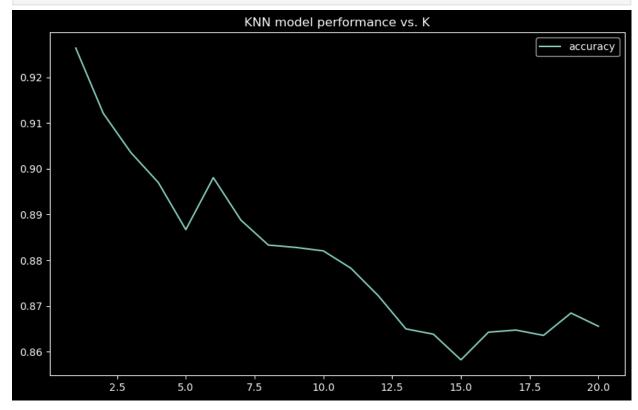
```
In []: from sklearn.neighbors import KNeighborsClassifier
    from sklearn.metrics import f1_score
    import matplotlib.pyplot as plt

model_scores = {}

X_train = pd.DataFrame(X_train).values
    y_train = pd.Series(y_train).values
    X_test = pd.DataFrame(X_test).values
    y_test = pd.Series(y_test).values

for k in range(1, 21):
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(X_train, y_train)
    y_pred = knn.predict(X_test)
    model_scores[k] = f1_score(y_test, y_pred)

pd.DataFrame(model_scores, index=['accuracy']).T.plot(figsize=(10, 6), title='KNN mode
plt.show()
```

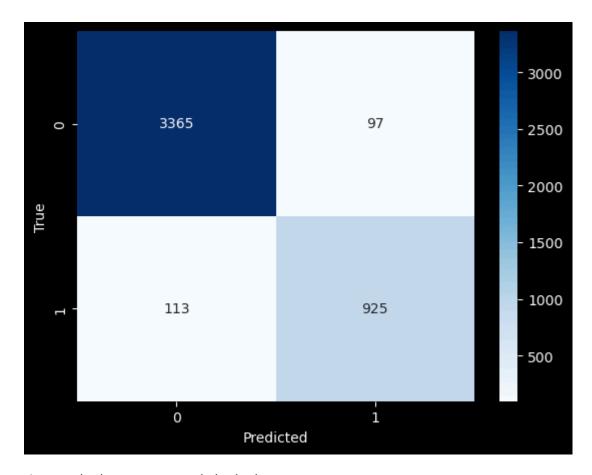


```
Out[]: {1: 0.9263746505125815,
         2: 0.912109375,
         3: 0.903558052434457,
         4: 0.8969873663751216,
         5: 0.8866855524079319,
         6: 0.8980582524271845,
         7: 0.8887832699619773,
         8: 0.8833172613307618,
         9: 0.8827977315689982,
         10: 0.8820414058738566,
         11: 0.8782567503552818,
         12: 0.872216844143272,
         13: 0.8649928943628613,
         14: 0.8638318203535595,
         15: 0.8582195007065474,
         16: 0.8642685851318944,
         17: 0.8647365923113431,
         18: 0.8635710866443275,
         19: 0.8684582743988686,
         20: 0.8655581947743468}
```

Si bien el score más alto se alcanza para k=1, esto crearía un modelo poco robusto, pues es muy susceptible al sobreajuste. Se puede observar, en cambio, que hay un máximo local para k=6, por lo que elegiremos este valor.

• Elabore un mapa de calor para la matriz de confusión asociada al valor óptimo de k. Interprete verbalmente cada resultado mostrado en dicha matriz.

```
from sklearn.metrics import confusion matrix
In [ ]:
        import seaborn as sns
        import matplotlib.pyplot as plt
        knn = KNeighborsClassifier(n neighbors=6)
        knn.fit(X_train, y_train)
        y_pred = knn.predict(X_test)
        cm = confusion_matrix(y_test, y_pred)
        array([[3365,
                        97],
Out[ ]:
               [ 113, 925]], dtype=int64)
In [ ]: sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
        plt.xlabel('Predicted')
        plt.ylabel('True')
        plt.show()
```



Los resultados se resumen de la siguiente manera:

• Verdaderos negativos: 3365

• Falsos positivos: 97

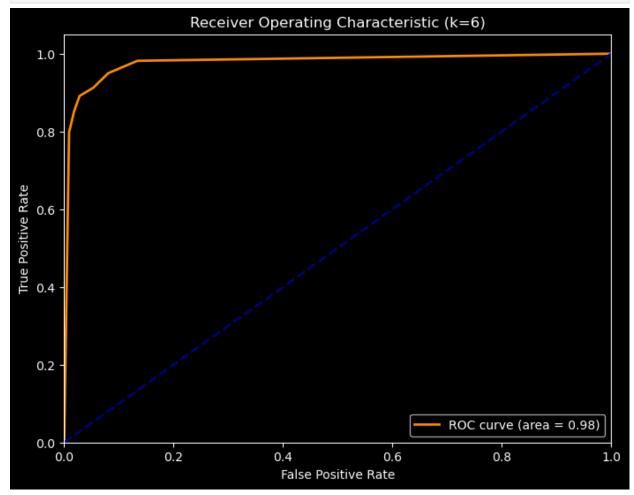
• Falsos negativos: 113

Verdaderos positivos: 925

• Obtenga e interprete la gráfica de la curva ROC para el valor óptimo de k.

```
In [ ]: from sklearn.metrics import roc_curve, auc
        import matplotlib.pyplot as plt
        y_proba = knn.predict_proba(X_test)[:, 1] # Probabilidades de la clase positiva
        fpr, tpr, _ = roc_curve(y_test, y_proba) # Calcula FPR (tasa de falsos positivos) y 1
        print(fpr, tpr)
                   0.00895436 0.01790872 0.02801849 0.05314847 0.08058925
         0.13373772 1. ] [0. 0.79768786 0.85067437 0.8911368 0.91233141 0.949
        90366
         0.98169557 1.
                             ]
In [ ]: roc_auc = auc(fpr, tpr) # Calcula el área bajo la curva ROC
        plt.figure(figsize=(8, 6))
        plt.plot(fpr, tpr, color='darkorange', lw=2, label=f'ROC curve (area = {roc_auc:.2f})'
        plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--')
        plt.xlim([0.0, 1.0])
        plt.ylim([0.0, 1.05])
        plt.xlabel('False Positive Rate')
        plt.ylabel('True Positive Rate')
```

```
plt.title('Receiver Operating Characteristic (k=6)')
plt.legend(loc="lower right")
plt.show()
```



El gráfico de la curva ROC se muestra arriba. El área bajo la curva ROC (AUC-ROC) es 0.95. Esto indica que el modelo tiene un excelente rendimiento en general, con una alta capacidad para discriminar entre las clases positiva y negativa.

Interpretación detallada:

Puntos en la curva: Cada punto en la curva ROC representa un umbral de decisión diferente para clasificar las muestras como positivas o negativas. Eje x (Tasa de Falsos Positivos - FPR): Indica la proporción de muestras negativas que se clasificaron incorrectamente como positivas. Eje y (Tasa de Verdaderos Positivos - TPR): Indica la proporción de muestras positivas que se clasificaron correctamente como positivas. Curva ideal: Una curva ROC ideal estaría lo más cerca posible de la esquina superior izquierda, lo que significa que el modelo tiene una alta tasa de verdaderos positivos y una baja tasa de falsos positivos. Línea diagonal: La línea diagonal punteada representa el rendimiento de un clasificador aleatorio, que no tiene capacidad para discriminar entre las clases. Conclusión:

En este caso, la curva ROC está muy cerca de la esquina superior izquierda y el AUC-ROC es 0.95, lo que indica que el modelo tiene un rendimiento excelente y es capaz de distinguir con precisión entre las clases positiva y negativa en la mayoría de los casos.